ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO GIỮA KÌ

TÊN ĐỀ TÀI:

MULTI-TASK LEARNING CHO PHÂN LOẠI CẢM XÚC VÀ CHỦ ĐỀ PHẢN HỒI SINH VIÊN TIẾNG VIỆT: SO SÁNH TEXTCNN VÀ PHOBERT

Ngành: Khoa học dữ liệu

Môn học: Lập trình Python nâng cao (858043)

Giảng viên hướng dẫn: TS. Trịnh Tấn Đạt

SINH VIÊN THỰC HIỆN:

Đinh Quang Minh (3123580024) — Nhóm trưởng

Dương Tấn Cường (3123580004)

Lê Thành Duy (3123580007)

Thành phố Hồ Chí Minh, tháng 11 năm 2026

BẢNG PHÂN CÔNG CÔNG VIỆC

Bảng dưới đây trình bày phân công công việc của nhóm. Tỷ lệ đóng góp được chốt theo khối lượng thực hiện: Đinh Quang Minh 33.4%, Dương Tấn Cường 33.3%, Lê Thành Duy 33.3%.

Bảng 1: Bảng phân công công việc của nhóm

STT	Họ và tên	MSSV	Nội dung công việc chính	Tỷ lệ
1	Đinh Quang Minh	3123580024	Thiết kế pipeline; data loader; EDA; baseline TF-IDF; TextCNN; PhoBERT; keyword-aware; distillation; kiểm định thống kê; demo; tổng hợp báo cáo.	33.4%
2	Dương Tấn Cường	3123580004	Kiểm tra label mapping và data audit; EDA; baseline; TextCNN multi-task; calibration; robustness; review báo cáo và kết quả.	33.3%
3	Lê Thành Duy	3123580007	Tiền xử lý dữ liệu; TextCNN single-task; TextCNN multi-task; student distillation; demo Streamlit; slide/video; kiểm tra tái lập.	33.3%
			Tổng cộng	**100.0%**

Ghi chú: Các đầu việc có tính hỗ trợ chéo; cả ba thành viên cùng tham gia kiểm tra kết quả, đọc báo cáo và chuẩn bị phần bảo vệ.

TÓM TẮT

Phản hồi sinh viên là nguồn dữ liệu quan trọng cho công tác đảm bảo chất lượng giáo dục, nhưng việc đọc và tổng hợp thủ công thường tốn thời gian và dễ bỏ sót vấn đề. Báo cáo này xây dựng một hệ thống multi-task learning để dự đoán đồng thời **cảm xúc** (tiêu cực, trung tính, tích cực) và **chủ đề** (giảng viên, chương trình đào tạo, cơ sở vật chất, khác) cho từng câu phản hồi tiếng Việt trên bộ dữ liệu UIT-VSFC.

Nhóm so sánh TextCNN và PhoBERT trong cùng một kiến trúc chia sẻ biểu diễn, sau đó bổ sung **keyword-aware topic head** với 12 đặc trưng từ khóa và một auxiliary loss. Kết quả trên test cho thấy PhoBERT keyword-aware đạt macro-F1 sentiment 0.7788, macro-F1 topic 0.7633 và joint accuracy 0.8054 ở seed 42. Đánh giá 3 seed cho kết quả trung bình lần lượt 0.7760, 0.7597 và 0.7989, cao hơn PhoBERT frozen ở topic và joint accuracy; kiểm định McNemar và bootstrap xác nhận cải thiện topic/joint nhất quán qua cả 3 seed.

Để triển khai trên CPU, nhóm distill PhoBERT teacher sang TextCNN student. Student chỉ có 407.055 tham số, nhỏ hơn khoảng 332 lần và nhanh hơn khoảng 27.6 lần so với teacher, trong khi vẫn giữ topic-F1 0.7607 và joint accuracy 0.7766 (trung bình 3 seed). Báo cáo cũng đánh giá calibration bằng temperature scaling, robustness với mất dấu/teencode/typo/emoji/đảo trật tự từ, và hạn chế single-label khi câu chứa nhiều chủ đề. Kết quả cho thấy mô hình có giá trị thực tế như một công cụ hỗ trợ phân loại và ưu tiên phản hồi, không thay thế đánh giá của con người.

MỤC LỤC

BẢNG PHÂN CÔNG CÔNG VIỆC i

TÓM TẮT ii

1 GIỚI THIỆU 1

1.1 Đặt vấn đề . . . 1
1.2 Mục tiêu . . . 1
1.3 Phạm vi . . . 2
1.4 Đóng góp chính . . . 2
1.5 Cấu trúc báo cáo . . . 2

2 DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ 3

2.1 Bộ dữ liệu UIT-VSFC . . . 3
2.2 Nhãn và quy ước . . . 4
2.3 Phân bố nhãn . . . 4
2.4 Nhận xét EDA . . . 5

3 PHƯƠNG PHÁP 6

3.1 Phát biểu bài toán . . . 6
3.2 Tiền xử lý . . . 6
3.3 TextCNN . . . 7
3.4 PhoBERT frozen . . . 7
3.5 Keyword-aware topic head . . . 7
3.6 Knowledge distillation . . . 8
3.7 Giao thức huấn luyện . . . 8
3.8 Độ đo và kiểm định . . . 8

4 THỰC NGHIỆM VÀ KẾT QUẢ **9**

4.1 Môi trường thực nghiệm 9

4.2 Kết quả một seed 9

4.3 Kết quả 3 seed 10

4.4 Kiểm định thống kê 10

4.5 Phân tích lỗi 11

4.6 Knowledge distillation 11

4.7 Calibration 12

4.8 Robustness 13

5 DEMO VÀ Ý NGHĨA THỰC TẾ **14**

5.1 Kiến trúc demo 14

5.2 Quy trình sử dụng 14

5.3 Ý nghĩa thực tế 15

5.4 Hạn chế của demo 15

6 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN **16**

6.1 Kết luận 16

6.2 Hạn chế 16

6.3 Hướng phát triển 17

TÀI LIỆU THAM KHẢO **18**

A MÃ NGUỒN VÀ LỆNH TÁI LẬP **19**

A.1 Cấu trúc chính 19

A.2 Lệnh chạy 19

A.3 Kiểm tra 20

DANH MỤC HÌNH

2.1 Phân bố cảm xúc trong tập train 5
2.2 Tương quan giữa cảm xúc và chủ đề 5

4.1 Reliability diagram cho topic sau calibration 12
4.2 So sánh robustness của teacher và student 13

DANH MỤC BẢNG

1 Bảng phân công công việc của nhóm i

2.1 Quy mô các split của UIT-VSFC 3
2.2 Mapping nhãn sentiment và topic 4
2.3 Phân bố nhãn sentiment theo split 4
2.4 Phân bố nhãn topic theo split 4

4.1 Cấu hình thực nghiệm 9
4.2 Kết quả test seed 42 9
4.3 Test mean $\pm$ std trên 3 seed 10
4.4 Tóm tắt McNemar và bootstrap trên 3 seed 10
4.5 So sánh teacher, hard-label student và distilled student (3 seed) 11
4.6 Chi phí suy luận trên CPU (100 câu test) 11
4.7 ECE trước và sau temperature scaling trên test 12
4.8 Topic-F1 dưới các perturbation (800 câu test) 13

CHƯƠNG 1

GIỚI THIỆU

1.1 Đặt vấn đề

Trong môi trường đại học, phản hồi của sinh viên là một trong những kênh quan trọng nhất để đánh giá chất lượng giảng dạy, chương trình đào tạo và cơ sở vật chất. Tuy nhiên, dữ liệu này thường tồn tại dưới dạng văn bản tự do, số lượng lớn và không có cấu trúc cố định. Việc đọc thủ công toàn bộ phản hồi vào cuối mỗi học kỳ không chỉ tốn thời gian mà còn khó tổng hợp theo chủ đề và dễ bỏ sót các vấn đề tiêu cực.

Một hệ thống tự động cần trả lời đồng thời hai câu hỏi:

- Phản hồi này thể hiện cảm xúc gì?
- Phản hồi này nói về chủ đề nào?

Hai câu hỏi có liên quan nhưng không đồng nhất. Một câu có thể tiêu cực về cơ sở vật chất nhưng tích cực về giảng viên; một câu khác có thể trung tính về chương trình đào tạo. Vì vậy, bài toán phù hợp với hướng **multi-task learning**: dùng chung một biểu diễn đầu vào và tối ưu đồng thời hai đầu ra.

1.2 Mục tiêu

Mục tiêu của đề tài gồm:

1. Xây dựng pipeline tái lập được cho UIT-VSFC: tải dữ liệu, kiểm tra nhãn, tiền xử lý, chia split và đánh giá.
2. So sánh TextCNN và PhoBERT trong cùng bài toán multi-task tiếng Việt.
3. Cải thiện topic head bằng đặc trưng từ khóa miền giáo dục và auxiliary loss.

4. Đánh giá độ ổn định bằng 3 seed, kiểm định thống kê và bootstrap.
5. Nén mô hình bằng knowledge distillation để chạy trên CPU.
6. Đánh giá calibration, robustness và xây dựng demo Streamlit có cảnh báo multi-topic.

1.3 Phạm vi

Đề tài tập trung vào phân loại mức câu trên UIT-VSFC, không đi vào aspect-based sentiment hay multi-label. Mô hình PhoBERT được đóng băng để phù hợp điều kiện CPU; không fine-tune toàn bộ encoder. Báo cáo không tuyên bố mô hình thay thế con người trong việc đánh giá giảng viên.

1.4 Đóng góp chính

- Một pipeline multi-task hoàn chỉnh cho UIT-VSFC, có baseline, TextCNN, PhoBERT và kiểm định thống kê.
- Một **keyword-aware PhoBERT** với 12 đặc trưng từ khóa và auxiliary loss, cải thiện topic-F1 và joint accuracy so với PhoBERT frozen.
- Một **TextCNN student** được distill từ PhoBERT, nhỏ hơn 332 lần và nhanh hơn khoảng 27.6 lần trên CPU.
- Đánh giá calibration và robustness, chỉ rõ điểm yếu với mất dấu, teencode và câu nhiều chủ đề.
- Demo Streamlit có model selector, confidence đã calibration, top-2 chủ đề và cảnh báo multi-topic.

1.5 Cấu trúc báo cáo

Chương 2 trình bày dữ liệu và EDA. Chương 3 mô tả phương pháp. Chương 4 trình bày thực nghiệm và kết quả. Chương 5 mô tả demo và ý nghĩa thực tế. Chương 6 kết luận và hướng phát triển.

CHƯƠNG 2

DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ

2.1 Bộ dữ liệu UIT-VSFC

UIT-VSFC là bộ dữ liệu phản hồi sinh viên tiếng Việt được giới thiệu bởi Nguyen và cộng sự [1]. Mỗi mẫu gồm một câu phản hồi, một nhãn cảm xúc và một nhãn chủ đề. Bộ dữ liệu có 16.175 câu, chia thành ba split chính thức.

Bảng 2.1: Quy mô các split của UIT-VSFC

Split	Số câu	Tỷ lệ
Train	11.426	70.6%
Dev	1.583	9.8%
Test	3.166	19.6%
Tổng	16.175	100.0%

2.2 Nhãn và quy ước

Bảng 2.2: Mapping nhãn sentiment và topic

Task	ID	Nhãn	Ý nghĩa
Sentiment	0	negative	Tiêu cực
Sentiment	1	neutral	Trung tính
Sentiment	2	positive	Tích cực
Topic	0	lecturer	Giảng viên
Topic	1	training_program	Chương trình đào tạo
Topic	2	facility	Cơ sở vật chất
Topic	3	others	Khác

Thứ tự nhãn được đọc từ `configs/label_map.json` và kiểm tra bằng ví dụ thực tế, không hardcode theo cảm tính.

2.3 Phân bố nhãn

Bảng 2.3: Phân bố nhãn sentiment theo split

Split	negative	neutral	positive
Train	5.325	458	5.643
Dev	705	73	805
Test	1.409	167	1.590

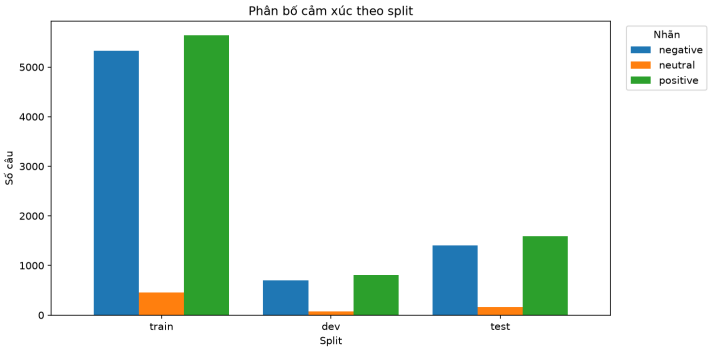
Bảng 2.4: Phân bố nhãn topic theo split

Split	lecturer	training_program	facility	others
Train	8.166	2.201	497	562
Dev	1.151	267	70	95
Test	2.290	572	145	159

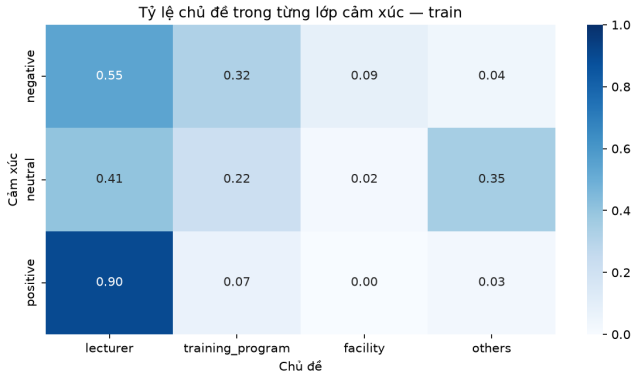
Hai đặc điểm mất cân bằng nổi bật:

- `neutral` chỉ chiếm khoảng 4.0% train, nên accuracy dễ gây ấn tượng sai; báo cáo dùng macro-F1.

- `lecturer` chiếm khoảng 71.5% train; các lớp `facility` và `others` ít hơn nhiều.



Hình 2.1: Phân bố cảm xúc trong tập train



Hình 2.2: Tương quan giữa cảm xúc và chủ đề

2.4 Nhận xét EDA

Các phát hiện chính:

- p95 độ dài câu train là 33 token; chọn `max_len=48` để cân bằng độ phủ và chi phí.
- Không có câu rỗng; không có trùng lặp giữa train/dev/test.
- Trong train có 1 câu trùng nội bộ; chưa xử lý nhưng ghi nhận.
- `facility` gần như luôn tiêu cực: 474/497 câu train.
- Sentiment và topic có tương quan mạnh, tạo nguy cơ shortcut: model có thể học "cứ facility là negative" thay vì học ngữ nghĩa.

Những đặc điểm này định hướng thiết kế: dùng class weight, macro-F1, kiểm tra per-class và phân tích lỗi định tính.

CHƯƠNG 3

PHƯƠNG PHÁP

3.1 Phát biểu bài toán

Cho câu phản hồi x được tách thành chuỗi token $x = (x_1, \ldots, x_n)$. Ta cần dự đoán:

$$y_s \in \{\text{negative}, \text{neutral}, \text{positive}\}, \qquad y_t \in \{\text{lecturer}, \text{training_program}, \text{facility}, \text{others}\}.$$

Với multi-task hard parameter sharing, model có một encoder chung và hai head. Hàm mất mát:

$$\mathcal{L} = \mathcal{L}_s + \lambda_t \mathcal{L}_t, \tag{3.1}$$

trong đó $\mathcal{L}_s$ và $\mathcal{L}_t$ là cross-entropy cho sentiment và topic; λ_t điều chỉnh mức ảnh hưởng của topic.

3.2 Tiền xử lý

Quy trình tiền xử lý:

1. Chuẩn hóa Unicode NFC và khoảng trắng.
2. Tách từ tiếng Việt bằng `underthesea`.
3. Xây vocabulary chỉ trên train, min frequency 2, tối đa 50.000 token.
4. Encode/Pad về `max_len=48`.
5. Với PhoBERT, dùng tokenizer chính thức của `vinai/phobert-base`.

Việc chỉ fit vocabulary trên train nhằm tránh rò rỉ dữ liệu.

3.3 TextCNN

TextCNN [3] dùng các convolution một chiều với kernel 3, 4, 5 để bắt n-gram cục bộ:

- Embedding 100 chiều.
- 100 filter cho mỗi kernel.
- Max-pooling theo thời gian.
- Shared hidden 256, dropout 0.5.
- Hai head tuyến tính cho sentiment và topic.

Mô hình có khoảng 0.41 triệu tham số, phù hợp CPU.

3.4 PhoBERT frozen

PhoBERT [2] là encoder tiếng Việt dựa trên RoBERTa. Trong đề tài, encoder được đóng băng; embedding `[CLS]` 768 chiều được trích một lần và cache:

$$\mathbf{h} = \text{PhoBERT}(x)_{[\text{CLS}]}.$$

Sau đó:

$$\mathbf{z} = \text{Dropout}(\text{ReLU}(\mathbf{W}\mathbf{h} + \mathbf{b})),$$

và hai head dự đoán sentiment/topic. Cách này giữ chi phí huấn luyện thấp trên CPU nhưng vẫn tận dụng biểu diễn ngữ nghĩa mạnh của PhoBERT.

3.5 Keyword-aware topic head

Phân tích lỗi cho thấy các cụm như `giảng_viên`, `cơ_sở`, `vật_chất`, `chương_trình` là tín hiệu miền rất mạnh. Nhóm bổ sung 12 đặc trưng:

- Với mỗi trong 4 topic: có keyword xuất hiện không.
- Mật độ keyword trong câu.
- Keyword có nằm trong 3 token cuối không.

Topic head nhận concatenation của shared hidden và vector keyword:

$$\mathbf{u} = [\mathbf{z}; \mathbf{k}], \qquad \boldsymbol{\ell}_t = \mathbf{W}_t \mathbf{u} + \mathbf{b}_t + \alpha \mathbf{W}_k \mathbf{k}.$$

Thêm một auxiliary loss buộc keyword head học trực tiếp từ keyword:

$$\mathcal{L} = \mathcal{L}_s + \lambda_t \mathcal{L}_t + \beta \mathcal{L}_{kw}, \tag{3.2}$$

với $\beta = 0.5$. Nhóm cũng dùng `sqrt_balanced` class weight để giảm thiên vị về lớp đa số.

3.6 Knowledge distillation

Teacher là PhoBERT keyword-aware; student là TextCNN multi-task. Soft label của teacher được cache cho train/dev/test. Student tối ưu:

$$\mathcal{L} = \mathcal{L}_{hard} + \beta T^2 \mathrm{KL}\left(\mathrm{softmax}(\mathbf{z}^{teacher}/T) \,\|\, \mathrm{softmax}(\mathbf{z}^{student}/T)\right), \tag{3.3}$$

với $T = 2.0$, $\beta = 0.5$, $\lambda_t = 1.0$. Mục tiêu không phải vượt teacher mà là giữ chất lượng gần teacher với chi phí nhỏ hơn nhiều.

3.7 Giao thức huấn luyện

- Chọn model bằng dev mean macro-F1; test chỉ đánh giá một lần cho cấu hình cuối.
- Early stopping theo dev; seed 42, 123, 2024 cho đánh giá 3 seed.
- TextCNN: Adam, learning rate 10^{-3}, batch 32, tối đa 20 epoch.
- PhoBERT head: Adam, learning rate 10^{-3}, batch 32, tối đa 30 epoch.
- Không fine-tune encoder PhoBERT.

3.8 Độ đo và kiểm định

- **Macro-F1** cho từng task, phù hợp mất cân bằng lớp.
- **Joint accuracy**: tỷ lệ câu đúng cả sentiment và topic.
- **McNemar exact test** trên correctness từng câu.
- **Bootstrap 95% CI** cho chênh lệch macro-F1/accuracy.
- **ECE** (Expected Calibration Error) cho calibration.

CHƯƠNG 4

THỰC NGHIỆM VÀ KẾT QUẢ

4.1 Môi trường thực nghiệm

Bảng 4.1: Cấu hình thực nghiệm

Thành phần	Giá trị
Python	3.12.15
PyTorch	2.14.1+cpu
Transformers	5.20.2
Device	CPU
Encoder	`vinai/phobert-base` (frozen)
TextCNN	embedding 100, filters 100, kernel 3/4/5
Seeds	42, 123, 2024

4.2 Kết quả một seed

Bảng 4.2: Kết quả test seed 42

Model	Sentiment F1	Topic F1	Joint
TF-IDF + Logistic Regression	0.7400	0.7247	0.7227
TextCNN single-task	0.7621	0.7355	0.7536
TextCNN multi-task	0.7556	0.7390	0.7552
PhoBERT frozen multi-task	0.7785	0.7428	0.7855
PhoBERT keyword-aware	**0.7788**	**0.7633**	**0.8054**

Nhận xét:

- TextCNN multi-task chưa cải thiện rõ so với single-task; có dấu hiệu negative transfer nhẹ ở sentiment.
- PhoBERT frozen tăng mạnh sentiment và joint so với TextCNN.
- Keyword-aware gần như giữ nguyên sentiment nhưng tăng topic 0.0205 và joint 0.0199 so với PhoBERT frozen.

4.3 Kết quả 3 seed

Bảng 4.3: Test mean ± std trên 3 seed

Model	Sentiment F1	Topic F1	Joint
TextCNN multi-task	0.7559 ± 0.0024	0.7508 ± 0.0103	0.7654 ± 0.0090
PhoBERT frozen	0.7679 ± 0.0101	0.7388 ± 0.0082	0.7612 ± 0.0291
PhoBERT keyword-aware	$\mathbf{0.7760 \pm 0.0060}$	$\mathbf{0.7597 \pm 0.0067}$	$\mathbf{0.7989 \pm 0.0059}$

Keyword-aware có mean tốt nhất ở cả ba metric và phương sai joint thấp hơn nhiều so với PhoBERT frozen. Điều này cho thấy cải thiện không chỉ đến từ một seed may mắn.

4.4 Kiểm định thống kê

Bảng 4.4: Tóm tắt McNemar và bootstrap trên 3 seed

So sánh	Task	McNemar p<0.05	CI loại 0
keyword vs frozen	topic	3/3	3/3
keyword vs frozen	joint	3/3	3/3
keyword vs frozen	sentiment	3/3	1/3
keyword vs TextCNN	joint	3/3	3/3
keyword vs TextCNN	topic	1/3	1/3
keyword vs TextCNN	sentiment	3/3	0/3

Kết luận thống kê:

- Cải thiện **topic** so với PhoBERT frozen là nhất quán.
- Cải thiện **joint accuracy** so với cả PhoBERT frozen và TextCNN là nhất quán.

- Chưa đủ bằng chứng để khẳng định cải thiện sentiment F1.
- So với TextCNN, lợi thế topic không ổn định qua các seed.

4.5 Phân tích lỗi

Một lỗi tiêu biểu là câu:

"cần phải cải thiện thêm, nhất là giảng viên"

PhoBERT frozen dự đoán facility 99.0%. Sau khi thêm keyword features và auxiliary loss, model dự đoán lecturer 49.9% (facility 44.5%) — đúng nhãn nhưng confidence thấp. Đây là hành vi hợp lý hơn so với việc tự tin sai.

Một lỗi khác là câu nhiều chủ đề:

"giảng viên tệ, cơ sở vật chất lỏ"

Model dự đoán facility 83.7%, lecturer 15.6%. Đây không phải lỗi softmax: bài toán hiện là single-label, nên model chỉ chọn chủ đề trội. Demo đã thêm cảnh báo multi-topic và hiển thị top-2 để tránh hiểu nhầm.

4.6 Knowledge distillation

Bảng 4.5: So sánh teacher, hard-label student và distilled student (3 seed)

Model	Sentiment F1	Topic F1	Joint
PhoBERT teacher	**0.7760 ± 0.0060**	0.7597 ± 0.0067	**0.7989 ± 0.0059**
TextCNN hard-label	0.7559 ± 0.0024	0.7508 ± 0.0103	0.7654 ± 0.0090
TextCNN distilled	0.7627 ± 0.0047	**0.7607 ± 0.0102**	0.7766 ± 0.0087

Bảng 4.6: Chi phí suy luận trên CPU (100 câu test)

Metric	Teacher	Student	Tỷ lệ
Parameters	135.198.571	407.055	332× ít hơn
Estimated size	515.74 MB	1.55 MB	332× nhỏ hơn
Latency	63.68 ms/câu	2.30 ms/câu	27.6× nhanh hơn
Throughput	15.7 câu/s	433.9 câu/s	27.6×

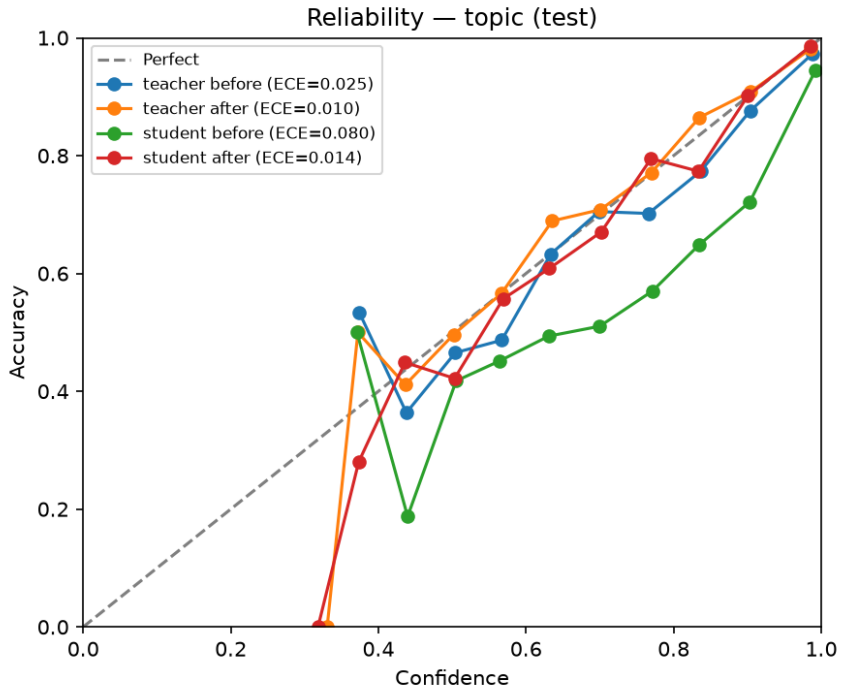
Distillation tăng đều cả ba metric so với TextCNN hard-label. Student gần như ngang teacher ở topic, thấp hơn ở sentiment/joint, nhưng nhỏ và nhanh hơn rất nhiều. Đây là trade-off phù hợp cho triển khai CPU.

4.7 Calibration

Bảng 4.7: ECE trước và sau temperature scaling trên test

Model	Task	T	ECE trước	ECE sau
Teacher	sentiment	1.366	0.0242	0.0215
Teacher	topic	1.230	0.0254	**0.0097**
Student	sentiment	1.930	0.0658	**0.0166**
Student	topic	1.823	0.0805	**0.0145**

Student overconfident hơn teacher trước calibration. Sau temperature scaling, ECE giảm mạnh, đặc biệt ở student. Accuracy không đổi vì temperature chỉ sửa confidence, không sửa argmax.

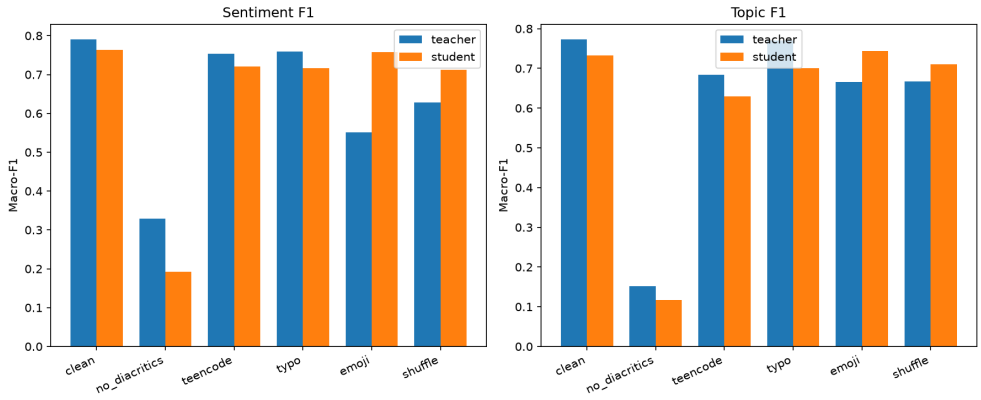


Hình 4.1: Reliability diagram cho topic sau calibration

4.8 Robustness

Bảng 4.8: Topic-F1 dưới các perturbation (800 câu test)

Variant	Teacher	Student
Clean	0.7727	0.7322
Không dấu	0.1517	0.1165
Teencode	0.6833	0.6303
Typo	0.7699	0.7005
Emoji	0.6661	**0.7440**
Đảo trật tự từ	0.6678	**0.7099**



Hình 4.2: So sánh robustness của teacher và student

Kết quả cho thấy mất dấu là điểm yếu nghiêm trọng nhất của cả hai mô hình. Teacher nhạy với emoji và đảo trật tự từ hơn student; student bền vững hơn ở hai perturbation này nhưng yếu hơn ở clean test.

CHƯƠNG 5

DEMO VÀ Ý NGHĨA THỰC TẾ

5.1 Kiến trúc demo

Demo được xây dựng bằng Streamlit, cho phép chọn:

- **PhoBERT teacher**: chính xác hơn, chậm hơn.
- **TextCNN student**: nhỏ, nhanh, phù hợp CPU.

Mỗi dự đoán hiển thị:

- nhãn cảm xúc và chủ đề;
- confidence đã calibration;
- xác suất từng lớp;
- top-2 chủ đề;
- từ khóa chủ đề phát hiện;
- latency và số tham số;
- cảnh báo khi confidence thấp hoặc câu có nhiều chủ đề.

5.2 Quy trình sử dụng

1. Nhập một câu phản hồi.
2. Chọn teacher hoặc student.
3. Xem nhãn, confidence, top-2 và keyword.

4. Nếu có cảnh báo multi-topic, người dùng biết rằng model chỉ chọn chủ đề trội.
5. Chuyển kết quả cho người phụ trách để xem lại.

5.3 Ý nghĩa thực tế

Giá trị của hệ thống không nằm ở việc thay thế con người mà ở khả năng **triage** phản hồi:

- Lọc nhanh các phản hồi tiêu cực.
- Nhóm phản hồi theo chủ đề để chuyển đúng đơn vị.
- Ưu tiên các vấn đề nghiêm trọng.
- Theo dõi xu hướng giữa các học kỳ.
- Hỗ trợ kiểm định và cải tiến chất lượng.

Ví dụ, cặp *negative* + *lecturer* gợi ý cần xem lại phản hồi về giảng dạy; *negative* + *facility* gợi ý cần kiểm tra phòng học/thiết bị. Hệ thống chạy trên CPU, chi phí thấp, có thể triển khai nội bộ để tránh gửi dữ liệu sinh viên lên cloud.

5.4 Hạn chế của demo

- Chỉ là single-label topic, không phải multi-label.
- Chưa xử lý tốt mất dấu và teencode.
- Confidence đã calibration nhưng không đảm bảo đúng trong mọi miền.
- Không có đánh giá cross-domain.

CHƯƠNG 6

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Kết luận

Đề tài đã xây dựng một pipeline multi-task hoàn chỉnh cho UIT-VSFC, so sánh TextCNN và PhoBERT, bổ sung keyword-aware topic head, đánh giá 3 seed và kiểm định thống kê. Kết quả chính:

- PhoBERT keyword-aware đạt mean test sentiment-F1 0.7760, topic-F1 0.7597, joint 0.7989.
- Cải thiện topic và joint so với PhoBERT frozen là nhất quán qua 3 seed.
- TextCNN student distilled nhỏ hơn 332 lần, nhanh hơn 27.6 lần, vẫn giữ topic-F1 0.7607 và joint 0.7766.
- Calibration giảm ECE mạnh cho student; robustness chỉ ra mất dấu là điểm yếu lớn nhất.
- Demo Streamlit hỗ trợ chọn model, confidence đã calibration, top-2 và cảnh báo multi-topic.

6.2 Hạn chế

- PhoBERT chưa được fine-tune; chỉ train head.
- Dataset nhỏ, một miền, chưa kiểm chứng cross-domain.
- Bài toán topic là single-label; câu nhiều chủ đề chưa được xử lý đúng bản chất.
- Chưa có multi-label annotation.
- Robustness với mất dấu và teencode còn yếu.

6.3 Hướng phát triển

1. Fine-tune 1–2 layer cuối PhoBERT hoặc dùng LoRA nếu có GPU.
2. Gán nhãn multi-label cho một tập con và xây dựng multi-label topic head.
3. Bổ sung cross-domain test trên dữ liệu review ngoài UIT-VSFC.
4. Data augmentation cho teencode/không dấu.
5. Calibration nâng cao (temperature theo lớp, label smoothing).
6. Đóng gói API/Docker và dashboard cho đơn vị đảm bảo chất lượng.

TÀI LIỆU THAM KHẢO

[1] Nguyen, V. D., Nguyen, D. Q., Nguyen, T. T., and Pham, T. H. (2018). *UIT-VSFC: Vietnamese Students' Feedback Corpus for Sentiment Analysis*. In Proceedings of the 10th International Conference on Knowledge and Systems Engineering (KSE).

[2] Nguyen, D. Q. and Nguyen, A. T. (2020). *PhoBERT: Pre-trained Language Models for Vietnamese*. In Findings of the Association for Computational Linguistics: EMNLP 2020.

[3] Kim, Y. (2014). *Convolutional Neural Networks for Sentence Classification*. In Proceedings of EMNLP 2014.

[4] Caruana, R. (1997). *Multitask Learning*. Machine Learning, 28(1), 41–75.

[5] Hinton, G., Vinyals, O., and Dean, J. (2015). *Distilling the Knowledge in a Neural Network*. NIPS Deep Learning and Representation Learning Workshop.

[6] Guo, C., Pleiss, G., Sun, Y., and Weinberger, K. Q. (2017). *On Calibration of Modern Neural Networks*. In Proceedings of ICML 2017.

[7] McNemar, Q. (1947). *Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages*. Psychometrika, 12(2), 153–157.

Appendix A

MÃ NGUỒN VÀ LỆNH TÁI LẬP

A.1 Cấu trúc chính

```
configs/        # hyperparameters
src/data/       # load, preprocess, dataset, EDA
src/models/     # TextCNN, PhoBERT heads
src/            # train, predict, calibration, robustness
app/            # Streamlit demo
reports/        # báo cáo, metric, hình
tests/          # unit tests
```

A.2 Lệnh chạy

```
.\scripts\activate.ps1
python -m src.data.load
python -m src.data.eda
python -m src.models.baseline
python -m src.train_textcnn --task both
python -m src.train_textcnn_multitask
python -m src.train_phobert_multitask
python -m src.train_phobert_keyword_multitask
python -m src.data.teacher_logits
python -m src.train_textcnn_distill
python -m src.calibration
python -m src.evaluate_robustness
python -m src.statistical_tests
.\scripts\run_demo.ps1
```

A.3 Kiểm tra

```
pytest
ruff check src tests scripts app --no-cache
```