ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA TOÁN - ỨNG DỤNG

BÁO CÁO GIỮA KÌ

TÊN ĐỀ TÀI:

MULTI-TASK LEARNING CHO PHÂN LOẠI CẢM XÚC VÀ CHỦ ĐỀ PHẢN HỒI SINH VIÊN TIẾNG VIỆT: SO SÁNH TEXTCNN VÀ PHOBERT

Ngành: Khoa học dữ liệu

Môn học: Lập trình Python nâng cao (858043)

Giảng viên hướng dẫn: TS. Trịnh Tấn Đạt

SINH VIÊN THỰC HIỆN:

Đinh Quang Minh (3123580024) — Nhóm trưởng
Dương Tấn Cường (3123580004)
Lê Thành Duy (3123580007)

Thành phố Hồ Chí Minh, tháng 11 năm 2026

BẢNG PHÂN CÔNG CÔNG VIỆC

Bảng dưới đây trình bày phân công công việc của nhóm. Tỷ lệ đóng góp được chốt theo khối lượng thực hiện: Đinh Quang Minh 33.4%, Dương Tấn Cường 33.3%, Lê Thành Duy 33.3%.

Bảng 1: Bảng phân công công việc của nhóm

STT	Họ và tên	MSSV	Nội dung công việc chính	Tỷ lệ
1	Đinh Quang Minh	3123580024	Thiết kế pipeline; data loader; EDA; baseline TF-IDF; TextCNN; PhoBERT; keyword-aware; distillation; kiểm định thống kê; demo; tổng hợp báo cáo.	33.4%
2	Dương Tấn Cường	3123580004	Kiểm tra label mapping và data audit; EDA; baseline; TextCNN multi-task; calibration; robustness; review báo cáo và kết quả.	33.3%
3	Lê Thành Duy	3123580007	Tiền xử lý dữ liệu; TextCNN single-task; TextCNN multi-task; student distillation; demo Streamlit; slide/video; kiểm tra tái lập.	33.3%
			Tổng cộng	**100.0%**

Ghi chú: Các đầu việc có tính hỗ trợ chéo; cả ba thành viên cùng tham gia kiểm tra kết quả, đọc báo cáo và chuẩn bị phần bảo vệ.

TÓM TẮT

Phản hồi sinh viên là nguồn dữ liệu quan trọng cho công tác đảm bảo chất lượng giáo dục, nhưng việc đọc và tổng hợp thủ công thường tốn thời gian và dễ bỏ sót vấn đề. Báo cáo này xây dựng một hệ thống multi-task learning để dự đoán đồng thời **cảm xúc** (tiêu cực, trung tính, tích cực) và **chủ đề** (giảng viên, chương trình đào tạo, cơ sở vật chất, khác) cho từng câu phản hồi tiếng Việt trên bộ dữ liệu UIT-VSFC.

Nhóm so sánh TextCNN và PhoBERT trong cùng một kiến trúc chia sẻ biểu diễn, sau đó bổ sung **keyword-aware topic head** với 12 đặc trưng từ khóa và một auxiliary loss. Kết quả trên test cho thấy PhoBERT keyword-aware đạt macro-F1 sentiment 0.7788, macro-F1 topic 0.7633 và joint accuracy 0.8054 ở seed 42. Đánh giá 3 seed cho kết quả trung bình lần lượt 0.7760, 0.7597 và 0.7989, cao hơn PhoBERT frozen ở topic và joint accuracy; kiểm định McNemar và bootstrap xác nhận cải thiện topic/joint nhất quán qua cả 3 seed.

Để triển khai trên CPU, nhóm distill PhoBERT teacher sang TextCNN student. Student chỉ có 407.055 tham số, nhỏ hơn khoảng 332 lần và nhanh hơn khoảng 27.6 lần so với teacher, trong khi vẫn giữ topic-F1 0.7607 và joint accuracy 0.7766 (trung bình 3 seed). Báo cáo cũng đánh giá calibration bằng temperature scaling, robustness với mất dấu/teencode/typo/emoji/đảo trật tự từ, và hạn chế single-label khi câu chứa nhiều chủ đề. Kết quả cho thấy mô hình có giá trị thực tế như một công cụ hỗ trợ phân loại và ưu tiên phản hồi, không thay thế đánh giá của con người.

MỤC LỤC

BẢNG PHÂN CÔNG CÔNG VIỆC i

TÓM TẮT ii

1 GIỚI THIỆU 1

1.1 Đặt vấn đề . . . 1
1.2 Mục tiêu . . . 1
1.3 Phạm vi . . . 2
1.4 Đóng góp chính . . . 2
1.5 Nghiên cứu liên quan . . . 2
1.5.1 Phân tích cảm xúc và chủ đề tiếng Việt . . . 2
1.5.2 Multi-task learning . . . 3
1.5.3 TextCNN và transformer . . . 3
1.5.4 Distillation và triển khai . . . 3
1.5.5 Calibration và robustness . . . 3
1.5.6 Khoảng trống . . . 4
1.6 Cấu trúc báo cáo . . . 4

2 DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ 5

2.1 Bộ dữ liệu UIT-VSFC . . . 5
2.2 Nhãn và quy ước . . . 6
2.3 Phân bố nhãn . . . 6
2.4 Nhận xét EDA . . . 7

3 PHƯƠNG PHÁP 9

3.1 Phát biểu bài toán . . . 9
3.2 Tiền xử lý . . . 9

3.3 TextCNN . . . 10
3.4 PhoBERT frozen . . . 10
3.5 Keyword-aware topic head . . . 10
3.6 Knowledge distillation . . . 11
3.7 Giao thức huấn luyện . . . 11
3.8 Thiết kế thực nghiệm . . . 11
3.9 Độ đo và kiểm định . . . 12

4 THỰC NGHIỆM VÀ KẾT QUẢ 14
4.1 Môi trường thực nghiệm . . . 14
4.2 Kết quả một seed . . . 14
4.3 Kết quả 3 seed . . . 15
4.4 Kiểm định thống kê . . . 15
4.5 Ablation và phân tích per-class . . . 16
4.6 Phân tích lỗi . . . 17
4.7 Knowledge distillation . . . 17
4.8 Calibration . . . 18
4.9 Robustness . . . 19
4.10 Thảo luận . . . 20
4.10.1 TextCNN và PhoBERT . . . 20
4.10.2 TextCNN multi-task có thực sự tốt hơn? . . . 20
4.10.3 Keyword-aware: lợi ích và rủi ro . . . 20
4.10.4 Teacher hay student? . . . 21
4.10.5 Câu nhiều chủ đề . . . 21
4.10.6 Threats to validity . . . 21

5 DEMO VÀ Ý NGHĨA THỰC TẾ 22
5.1 Kiến trúc demo . . . 22
5.2 Quy trình sử dụng . . . 22
5.3 Ý nghĩa thực tế . . . 23
5.4 Hạn chế của demo . . . 23

6 KỸ NGHỆ PHẦN MỀM VÀ TÁI LẬP 24
6.1 Cấu trúc repository . . . 24

6.2 Pipeline dữ liệu 25
6.3 Quản lý cấu hình 25
6.4 Kiểm thử 25
6.5 Tái lập 26
6.6 Git và báo cáo 26
6.7 Hạn chế kỹ nghệ 27

7 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 28
7.1 Kết luận 28
7.2 Hạn chế 28
7.3 Bài học kinh nghiệm 29
7.4 Checklist tái lập 29
7.5 Hướng phát triển 29
7.6 Tổng kết 30

TÀI LIỆU THAM KHẢO 31

DANH MỤC HÌNH

2.1 Phân bố cảm xúc trong tập train 7
2.2 Tương quan giữa cảm xúc và chủ đề 7

4.1 Reliability diagram cho topic sau calibration 18
4.2 So sánh robustness của teacher và student 19

DANH MỤC BẢNG

1 Bảng phân công công việc của nhóm i

2.1 Quy mô các split của UIT-VSFC 5
2.2 Mapping nhãn sentiment và topic 6
2.3 Phân bố nhãn sentiment theo split 6
2.4 Phân bố nhãn topic theo split 6

3.1 Ma trận thực nghiệm 12

4.1 Cấu hình thực nghiệm 14
4.2 Kết quả test seed 42 14
4.3 Test mean $\pm$ std trên 3 seed 15
4.4 Tóm tắt McNemar và bootstrap trên 3 seed 15
4.5 Ablation từ các cấu hình có sẵn (test, seed 42) 16
4.6 Per-class test của PhoBERT keyword-aware (seed 42) 16
4.7 So sánh teacher, hard-label student và distilled student (3 seed) 17
4.8 Chi phí suy luận trên CPU (100 câu test) 17
4.9 ECE trước và sau temperature scaling trên test 18
4.10 Topic-F1 dưới các perturbation (800 câu test) 19

CHƯƠNG 1

GIỚI THIỆU

1.1 Đặt vấn đề

Trong môi trường đại học, phản hồi của sinh viên là một trong những kênh quan trọng nhất để đánh giá chất lượng giảng dạy, chương trình đào tạo và cơ sở vật chất. Tuy nhiên, dữ liệu này thường tồn tại dưới dạng văn bản tự do, số lượng lớn và không có cấu trúc cố định. Việc đọc thủ công toàn bộ phản hồi vào cuối mỗi học kỳ không chỉ tốn thời gian mà còn khó tổng hợp theo chủ đề và dễ bỏ sót các vấn đề tiêu cực.

Một hệ thống tự động cần trả lời đồng thời hai câu hỏi:

- Phản hồi này thể hiện cảm xúc gì?
- Phản hồi này nói về chủ đề nào?

Hai câu hỏi có liên quan nhưng không đồng nhất. Một câu có thể tiêu cực về cơ sở vật chất nhưng tích cực về giảng viên; một câu khác có thể trung tính về chương trình đào tạo. Vì vậy, bài toán phù hợp với hướng **multi-task learning**: dùng chung một biểu diễn đầu vào và tối ưu đồng thời hai đầu ra.

1.2 Mục tiêu

Mục tiêu của đề tài gồm:

1. Xây dựng pipeline tái lập được cho UIT-VSFC: tải dữ liệu, kiểm tra nhãn, tiền xử lý, chia split và đánh giá.
2. So sánh TextCNN và PhoBERT trong cùng bài toán multi-task tiếng Việt.
3. Cải thiện topic head bằng đặc trưng từ khóa miền giáo dục và auxiliary loss.

4. Đánh giá độ ổn định bằng 3 seed, kiểm định thống kê và bootstrap.
5. Nén mô hình bằng knowledge distillation để chạy trên CPU.
6. Đánh giá calibration, robustness và xây dựng demo Streamlit có cảnh báo multi-topic.

1.3 Phạm vi

Đề tài tập trung vào phân loại mức câu trên UIT-VSFC, không đi vào aspect-based sentiment hay multi-label. Mô hình PhoBERT được đóng băng để phù hợp điều kiện CPU; không fine-tune toàn bộ encoder. Báo cáo không tuyên bố mô hình thay thế con người trong việc đánh giá giảng viên.

1.4 Đóng góp chính

- Một pipeline multi-task hoàn chỉnh cho UIT-VSFC, có baseline, TextCNN, PhoBERT và kiểm định thống kê.
- Một **keyword-aware PhoBERT** với 12 đặc trưng từ khóa và auxiliary loss, cải thiện topic-F1 và joint accuracy so với PhoBERT frozen.
- Một **TextCNN student** được distill từ PhoBERT, nhỏ hơn 332 lần và nhanh hơn khoảng 27.6 lần trên CPU.
- Đánh giá calibration và robustness, chỉ rõ điểm yếu với mất dấu, teencode và câu nhiều chủ đề.
- Demo Streamlit có model selector, confidence đã calibration, top-2 chủ đề và cảnh báo multi-topic.

1.5 Nghiên cứu liên quan

Bài toán phân tích phản hồi sinh viên nằm ở giao điểm của ba hướng nghiên cứu: phân tích cảm xúc tiếng Việt, multi-task learning và tối ưu mô hình cho triển khai thực tế.

1.5.1 Phân tích cảm xúc và chủ đề tiếng Việt

UIT-VSFC [1] là một trong những bộ dữ liệu chuẩn cho phản hồi sinh viên tiếng Việt. Dữ liệu gốc tập trung vào phân loại cảm xúc mức câu; nhãn chủ đề được cung cấp như một bài toán phụ. Các nghiên cứu trước thường dùng TF-IDF, SVM, CNN hoặc BiLSTM. Với sự xuất hiện

của PhoBERT [2], các mô hình pretrained nhanh chóng trở thành baseline mạnh cho tiếng Việt nhờ biểu diễn ngữ cảnh tốt hơn.

Tuy nhiên, phần lớn nghiên cứu chỉ tối ưu một task hoặc đánh giá trên một seed. Điều này làm khó so sánh độ ổn định và chưa trả lời rõ câu hỏi: với dữ liệu nhỏ và mất cân bằng, multi-task có thực sự giúp ích không?

1.5.2 Multi-task learning

Caruana [4] mô tả multi-task learning như một cách dùng tín hiệu của task phụ để regularize và cải thiện biểu diễn chung. Hai chiến lược phổ biến:

- **Hard parameter sharing**: dùng chung encoder, tách head ở cuối.
- **Soft parameter sharing**: mỗi task có encoder riêng, ràng buộc tham số giữa các encoder.

Đề tài chọn hard sharing vì đơn giản, dễ triển khai trên CPU và phù hợp với hai task có liên quan. Rủi ro chính là *negative transfer*: task này kéo lùi task kia nếu phân bố hoặc độ khó khác nhau. Vì vậy báo cáo không chỉ so sánh multi-task với single-task mà còn kiểm tra per-class và hệ số λ_t.

1.5.3 TextCNN và transformer

TextCNN [3] là kiến trúc nhẹ, dùng convolution để bắt n-gram cục bộ. Ưu điểm là tốc độ và khả năng học từ đầu trên dữ liệu nhỏ. Nhược điểm là không mô hình hóa ngữ cảnh xa và phụ thuộc vào chất lượng embedding.

PhoBERT [2] khắc phục nhược điểm ngữ cảnh nhưng có chi phí suy luận lớn. Trong điều kiện không GPU, fine-tune toàn bộ PhoBERT là không thực tế; vì vậy đề tài dùng encoder đóng băng và chỉ train head. Đây là điểm cân bằng giữa chất lượng và chi phí.

1.5.4 Distillation và triển khai

Knowledge distillation [5] chuyển tri thức từ teacher sang student bằng soft label. Hướng này đặc biệt phù hợp khi teacher lớn nhưng môi trường triển khai chỉ có CPU. Thay vì cố gắng fine-tune teacher, đề tài dùng teacher đã có để tạo soft label, sau đó train student TextCNN nhỏ hơn hàng trăm lần.

1.5.5 Calibration và robustness

Các mô hình hiện đại thường quá tự tin; Guo và cộng sự [6] chỉ ra rằng confidence không phản ánh đúng xác suất đúng. Temperature scaling là phương pháp hậu xử lý đơn giản, chỉ dùng

dev để fit nhiệt độ. Bên cạnh đó, robustness với teencode, mất dấu và lỗi gõ là vấn đề thực tế của dữ liệu mạng xã hội/tiếng Việt.

1.5.6 Khoảng trống

Các công trình riêng lẻ đã giải quyết từng phần: multi-task, PhoBERT, distillation hoặc calibration. Đề tài kết hợp các thành phần này trong một pipeline nhỏ, chạy CPU, có kiểm định thống kê và demo. Đóng góp không nằm ở kiến trúc hoàn toàn mới mà ở việc đánh giá có hệ thống và chuyển hóa kết quả thành công cụ có thể dùng.

1.6 Cấu trúc báo cáo

Chương 2 trình bày dữ liệu và EDA. Chương 3 mô tả phương pháp. Chương 4 trình bày thực nghiệm và kết quả. Chương 5 mô tả demo và ý nghĩa thực tế. Chương 6 trình bày kỹ nghệ phần mềm và tái lập. Chương 7 kết luận và hướng phát triển.

Tóm tắt chương

Chương này đặt bài toán, mục tiêu, phạm vi và các đóng góp chính. Điểm cần nhấn mạnh là bài toán không chỉ là phân loại cảm xúc mà còn phải gắn cảm xúc với chủ đề để tạo ra tín hiệu có thể hành động. Chương tiếp theo mô tả dữ liệu và các đặc điểm phân bố ảnh hưởng đến thiết kế mô hình.

CHƯƠNG 2

DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ

2.1 Bộ dữ liệu UIT-VSFC

UIT-VSFC là bộ dữ liệu phản hồi sinh viên tiếng Việt được giới thiệu bởi Nguyen và cộng sự [1]. Mỗi mẫu gồm một câu phản hồi, một nhãn cảm xúc và một nhãn chủ đề. Bộ dữ liệu có 16.175 câu, chia thành ba split chính thức.

Bảng 2.1: Quy mô các split của UIT-VSFC

Split	Số câu	Tỷ lệ
Train	11.426	70.6%
Dev	1.583	9.8%
Test	3.166	19.6%
Tổng	16.175	100.0%

2.2 Nhãn và quy ước

Bảng 2.2: Mapping nhãn sentiment và topic

Task	ID	Nhãn	Ý nghĩa
Sentiment	0	negative	Tiêu cực
Sentiment	1	neutral	Trung tính
Sentiment	2	positive	Tích cực
Topic	0	lecturer	Giảng viên
Topic	1	training_program	Chương trình đào tạo
Topic	2	facility	Cơ sở vật chất
Topic	3	others	Khác

Thứ tự nhãn được đọc từ `configs/label_map.json` và kiểm tra bằng ví dụ thực tế, không hardcode theo cảm tính.

2.3 Phân bố nhãn

Bảng 2.3: Phân bố nhãn sentiment theo split

Split	negative	neutral	positive
Train	5.325	458	5.643
Dev	705	73	805
Test	1.409	167	1.590

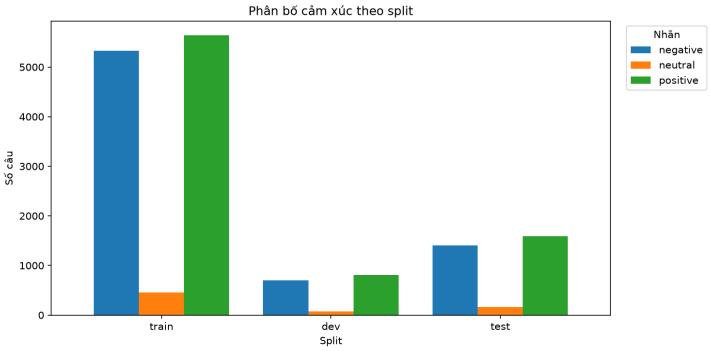
Bảng 2.4: Phân bố nhãn topic theo split

Split	lecturer	training_program	facility	others
Train	8.166	2.201	497	562
Dev	1.151	267	70	95
Test	2.290	572	145	159

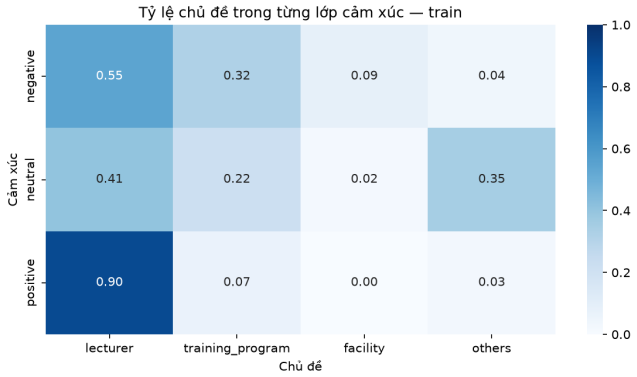
Hai đặc điểm mất cân bằng nổi bật:

- `neutral` chỉ chiếm khoảng 4.0% train, nên accuracy dễ gây ấn tượng sai; báo cáo dùng macro-F1.

- `lecturer` chiếm khoảng 71.5% train; các lớp `facility` và `others` ít hơn nhiều.



Hình 2.1: Phân bố cảm xúc trong tập train



Hình 2.2: Tương quan giữa cảm xúc và chủ đề

2.4 Nhận xét EDA

Các phát hiện chính:

- p95 độ dài câu train là 33 token; chọn `max_len=48` để cân bằng độ phủ và chi phí.
- Không có câu rỗng; không có trùng lặp giữa train/dev/test.
- Trong train có 1 câu trùng nội bộ; chưa xử lý nhưng ghi nhận.
- `facility` gần như luôn tiêu cực: 474/497 câu train.
- Sentiment và topic có tương quan mạnh, tạo nguy cơ shortcut: model có thể học "cứ facility là negative" thay vì học ngữ nghĩa.

Những đặc điểm này định hướng thiết kế: dùng class weight, macro-F1, kiểm tra per-class và phân tích lỗi định tính.

Tóm tắt chương

Chương này mô tả nguồn dữ liệu, quy ước nhãn và các đặc điểm mất cân bằng. Các phát hiện EDA giải thích vì sao báo cáo dùng macro-F1, class weight và phân tích per-class thay vì chỉ báo cáo accuracy. Chương tiếp theo trình bày kiến trúc TextCNN, PhoBERT, keyword-aware head và distillation.

CHƯƠNG 3

PHƯƠNG PHÁP

3.1 Phát biểu bài toán

Cho câu phản hồi x được tách thành chuỗi token $x = (x_1, \ldots, x_n)$. Ta cần dự đoán:

$$y_s \in \{\text{negative}, \text{neutral}, \text{positive}\}, \qquad y_t \in \{\text{lecturer}, \text{training_program}, \text{facility}, \text{others}\}.$$

Với multi-task hard parameter sharing, model có một encoder chung và hai head. Hàm mất mát:

$$\mathcal{L} = \mathcal{L}_s + \lambda_t \mathcal{L}_t, \tag{3.1}$$

trong đó $\mathcal{L}_s$ và $\mathcal{L}_t$ là cross-entropy cho sentiment và topic; λ_t điều chỉnh mức ảnh hưởng của topic.

3.2 Tiền xử lý

Quy trình tiền xử lý:

1. Chuẩn hóa Unicode NFC và khoảng trắng.
2. Tách từ tiếng Việt bằng `underthesea`.
3. Xây vocabulary chỉ trên train, min frequency 2, tối đa 50.000 token.
4. Encode/Pad về `max_len=48`.
5. Với PhoBERT, dùng tokenizer chính thức của `vinai/phobert-base`.

Việc chỉ fit vocabulary trên train nhằm tránh rò rỉ dữ liệu.

3.3 TextCNN

TextCNN [3] dùng các convolution một chiều với kernel 3, 4, 5 để bắt n-gram cục bộ:

- Embedding 100 chiều.
- 100 filter cho mỗi kernel.
- Max-pooling theo thời gian.
- Shared hidden 256, dropout 0.5.
- Hai head tuyến tính cho sentiment và topic.

Mô hình có khoảng 0.41 triệu tham số, phù hợp CPU.

3.4 PhoBERT frozen

PhoBERT [2] là encoder tiếng Việt dựa trên RoBERTa. Trong đề tài, encoder được đóng băng; embedding `[CLS]` 768 chiều được trích một lần và cache:

$$\mathbf{h} = \text{PhoBERT}(x)_{[\text{CLS}]}.$$

Sau đó:

$$\mathbf{z} = \text{Dropout}(\text{ReLU}(\mathbf{W}\mathbf{h} + \mathbf{b})),$$

và hai head dự đoán sentiment/topic. Cách này giữ chi phí huấn luyện thấp trên CPU nhưng vẫn tận dụng biểu diễn ngữ nghĩa mạnh của PhoBERT.

3.5 Keyword-aware topic head

Phân tích lỗi cho thấy các cụm như `giảng_viên`, `cơ_sở`, `vật_chất`, `chương_trình` là tín hiệu miền rất mạnh. Nhóm bổ sung 12 đặc trưng:

- Với mỗi trong 4 topic: có keyword xuất hiện không.
- Mật độ keyword trong câu.
- Keyword có nằm trong 3 token cuối không.

Topic head nhận concatenation của shared hidden và vector keyword:

$$\mathbf{u} = [\mathbf{z}; \mathbf{k}], \qquad \boldsymbol{\ell}_t = \mathbf{W}_t\mathbf{u} + \mathbf{b}_t + \alpha\mathbf{W}_k\mathbf{k}.$$

Thêm một auxiliary loss buộc keyword head học trực tiếp từ keyword:

$$\mathcal{L} = \mathcal{L}_s + \lambda_t\mathcal{L}_t + \beta\mathcal{L}_{kw}, \tag{3.2}$$

với $\beta = 0.5$. Nhóm cũng dùng `sqrt_balanced` class weight để giảm thiên vị về lớp đa số.

3.6 Knowledge distillation

Teacher là PhoBERT keyword-aware; student là TextCNN multi-task. Soft label của teacher được cache cho train/dev/test. Student tối ưu:

$$\mathcal{L} = \mathcal{L}_{hard} + \beta T^2 \mathrm{KL}\left(\mathrm{softmax}(\mathbf{z}^{teacher}/T) \,\|\, \mathrm{softmax}(\mathbf{z}^{student}/T)\right), \tag{3.3}$$

với $T = 2.0$, $\beta = 0.5$, $\lambda_t = 1.0$. Mục tiêu không phải vượt teacher mà là giữ chất lượng gần teacher với chi phí nhỏ hơn nhiều.

3.7 Giao thức huấn luyện

- Chọn model bằng dev mean macro-F1; test chỉ đánh giá một lần cho cấu hình cuối.
- Early stopping theo dev; seed 42, 123, 2024 cho đánh giá 3 seed.
- TextCNN: Adam, learning rate 10^{-3}, batch 32, tối đa 20 epoch.
- PhoBERT head: Adam, learning rate 10^{-3}, batch 32, tối đa 30 epoch.
- Không fine-tune encoder PhoBERT.

3.8 Thiết kế thực nghiệm

Thực nghiệm được chia thành các giai đoạn độc lập để dễ truy vết và tránh tune trên test.

Bảng 3.1: Ma trận thực nghiệm

ID	Mô hình	Mục đích	Seed
E0	Data audit + EDA	Kiểm tra nhãn, phân bố, trùng lặp, độ dài	–
E1	TF-IDF + Logistic Regression	Baseline tuyến tính, dễ giải thích	42
E2	TextCNN single-task	Baseline học sâu nhẹ, train từ đầu	42
E3	TextCNN multi-task	Đo ảnh hưởng của chia sẻ tham số	42, 123, 2024
E4	PhoBERT frozen multi-task	Tận dụng pretrained encoder trên CPU	42, 123, 2024
E5	PhoBERT keyword-aware	Đo ảnh hưởng của keyword + auxiliary loss	42, 123, 2024
E6	TextCNN distilled	Nén teacher thành student nhỏ	42, 123, 2024
E7	Calibration + robustness	Đánh giá độ tin cậy và độ bền	42

Các biến kiểm soát:

- Cùng split chính thức; không trộn test vào train.
- Cùng metric: macro-F1 và joint accuracy.
- Model selection chỉ dùng dev mean-F1.
- Với TextCNN, giữ nguyên kiến trúc khi so single/multi.
- Với PhoBERT, giữ nguyên encoder frozen khi so frozen/keyword.
- Mỗi cấu hình cuối được đánh giá test một lần; kết quả 3 seed báo cáo mean $\pm$ std.

Một số ablation không chạy đầy đủ do giới hạn thời gian, ví dụ grid search toàn bộ λ_t, temperature, hoặc số layer fine-tune. Báo cáo chỉ kết luận từ các cấu hình đã chạy và ghi rõ phần chưa kiểm chứng.

3.9 Độ đo và kiểm định

- **Macro-F1** cho từng task, phù hợp mất cân bằng lớp.
- **Joint accuracy**: tỷ lệ câu đúng cả sentiment và topic.
- **McNemar exact test** trên correctness từng câu.
- **Bootstrap 95% CI** cho chênh lệch macro-F1/accuracy.
- **ECE** (Expected Calibration Error) cho calibration.
- **Robustness**: mất dấu, teencode, typo, emoji, đảo trật tự từ.

Tóm tắt chương

Chương này trình bày công thức multi-task, cách tiền xử lý, kiến trúc TextCNN, PhoBERT frozen, keyword-aware head và knowledge distillation. Giao thức huấn luyện được thiết kế để chọn model bằng dev, đánh giá test một lần và lặp lại với 3 seed. Chương tiếp theo trình bày kết quả thực nghiệm và các kiểm định.

CHƯƠNG 4

THỰC NGHIỆM VÀ KẾT QUẢ

4.1 Môi trường thực nghiệm

Bảng 4.1: Cấu hình thực nghiệm

Thành phần	Giá trị
Python	3.12.15
PyTorch	2.14.1+cpu
Transformers	5.20.2
Device	CPU
Encoder	`vinai/phobert-base` (frozen)
TextCNN	embedding 100, filters 100, kernel 3/4/5
Seeds	42, 123, 2024

4.2 Kết quả một seed

Bảng 4.2: Kết quả test seed 42

Model	Sentiment F1	Topic F1	Joint
TF-IDF + Logistic Regression	0.7400	0.7247	0.7227
TextCNN single-task	0.7621	0.7355	0.7536
TextCNN multi-task	0.7556	0.7390	0.7552
PhoBERT frozen multi-task	0.7785	0.7428	0.7855
PhoBERT keyword-aware	**0.7788**	**0.7633**	**0.8054**

Nhận xét:

- TextCNN multi-task chưa cải thiện rõ so với single-task; có dấu hiệu negative transfer nhẹ ở sentiment.
- PhoBERT frozen tăng mạnh sentiment và joint so với TextCNN.
- Keyword-aware gần như giữ nguyên sentiment nhưng tăng topic 0.0205 và joint 0.0199 so với PhoBERT frozen.

4.3 Kết quả 3 seed

Bảng 4.3: Test mean ± std trên 3 seed

Model	Sentiment F1	Topic F1	Joint
TextCNN multi-task	0.7559 ± 0.0024	0.7508 ± 0.0103	0.7654 ± 0.0090
PhoBERT frozen	0.7679 ± 0.0101	0.7388 ± 0.0082	0.7612 ± 0.0291
PhoBERT keyword-aware	**0.7760 ± 0.0060**	**0.7597 ± 0.0067**	**0.7989 ± 0.0059**

Keyword-aware có mean tốt nhất ở cả ba metric và phương sai joint thấp hơn nhiều so với PhoBERT frozen. Điều này cho thấy cải thiện không chỉ đến từ một seed may mắn.

4.4 Kiểm định thống kê

Bảng 4.4: Tóm tắt McNemar và bootstrap trên 3 seed

So sánh	Task	McNemar p<0.05	CI loại 0
keyword vs frozen	topic	3/3	3/3
keyword vs frozen	joint	3/3	3/3
keyword vs frozen	sentiment	3/3	1/3
keyword vs TextCNN	joint	3/3	3/3
keyword vs TextCNN	topic	1/3	1/3
keyword vs TextCNN	sentiment	3/3	0/3

Kết luận thống kê:

- Cải thiện **topic** so với PhoBERT frozen là nhất quán.
- Cải thiện **joint accuracy** so với cả PhoBERT frozen và TextCNN là nhất quán.

- Chưa đủ bằng chứng để khẳng định cải thiện sentiment F1.
- So với TextCNN, lợi thế topic không ổn định qua các seed.

4.5 Ablation và phân tích per-class

Bảng 4.5 tổng hợp các so sánh có kiểm soát. Mỗi cặp chỉ thay một thành phần để có thể quy kết phần nào tạo ra chênh lệch.

Bảng 4.5: Ablation từ các cấu hình có sẵn (test, seed 42)

So sánh	Thay đổi	Δ Sent	Δ Topic	Δ Joint
TextCNN single → multi	Chia sẻ encoder, thêm topic head	-0.0065	+0.0035	+0.0016
PhoBERT frozen → keyword	Thêm 12 keyword + aux loss	+0.0003	+0.0205	+0.0199
TextCNN hard → distilled	Học thêm soft label của teacher	+0.0068	+0.0099	+0.0112

Diễn giải:

- Multi-task TextCNN **không** cải thiện sentiment; có dấu hiệu negative transfer nhẹ. Topic tăng nhẹ nhưng chưa đủ lớn để kết luận.
- Keyword features cải thiện topic rõ rệt nhưng gần như không đổi sentiment, đúng với thiết kế chỉ can thiệp vào topic head.
- Distillation cải thiện cả ba metric so với student hard-label, cho thấy soft label của teacher có tác dụng regularize.

Bảng 4.6: Per-class test của PhoBERT keyword-aware (seed 42)

Task	Lớp	Precision	Recall	F1
Sentiment	negative	0.9262	0.9446	0.9353
Sentiment	neutral	0.4966	0.4311	0.4615
Sentiment	positive	0.9413	0.9377	0.9395
Topic	lecturer	0.9235	0.9284	0.9260
Topic	training_program	0.7518	0.7255	0.7384
Topic	facility	0.8766	0.9310	0.9030
Topic	others	0.4873	0.4843	0.4858

Hai điểm đáng chú ý:

- `neutral` vẫn là lớp khó nhất (F1 0.4615), do chỉ có 167 mẫu test và tín hiệu từ vựng mờ.
- `others` có F1 thấp (0.4858), vì đây là lớp "phần còn lại", không có keyword đặc trưng và rất đa dạng.

4.6 Phân tích lỗi

Một lỗi tiêu biểu là câu:

"cần phải cải thiện thêm, nhất là giảng viên"

PhoBERT frozen dự đoán facility 99.0%. Sau khi thêm keyword features và auxiliary loss, model dự đoán lecturer 49.9% (facility 44.5%) — đúng nhãn nhưng confidence thấp. Đây là hành vi hợp lý hơn so với việc tự tin sai.

Một lỗi khác là câu nhiều chủ đề:

"giảng viên tệ, cơ sở vật chất lỏ"

Model dự đoán facility 83.7%, lecturer 15.6%. Đây không phải lỗi softmax: bài toán hiện là single-label, nên model chỉ chọn chủ đề trội. Demo đã thêm cảnh báo multi-topic và hiển thị top-2 để tránh hiểu nhầm.

4.7 Knowledge distillation

Bảng 4.7: So sánh teacher, hard-label student và distilled student (3 seed)

Model	Sentiment F1	Topic F1	Joint
PhoBERT teacher	**0.7760 ± 0.0060**	0.7597 ± 0.0067	**0.7989 ± 0.0059**
TextCNN hard-label	0.7559 ± 0.0024	0.7508 ± 0.0103	0.7654 ± 0.0090
TextCNN distilled	0.7627 ± 0.0047	**0.7607 ± 0.0102**	0.7766 ± 0.0087

Bảng 4.8: Chi phí suy luận trên CPU (100 câu test)

Metric	Teacher	Student	Tỷ lệ
Parameters	135.198.571	407.055	332× ít hơn
Estimated size	515.74 MB	1.55 MB	332× nhỏ hơn
Latency	63.68 ms/câu	2.30 ms/câu	27.6× nhanh hơn
Throughput	15.7 câu/s	433.9 câu/s	27.6×

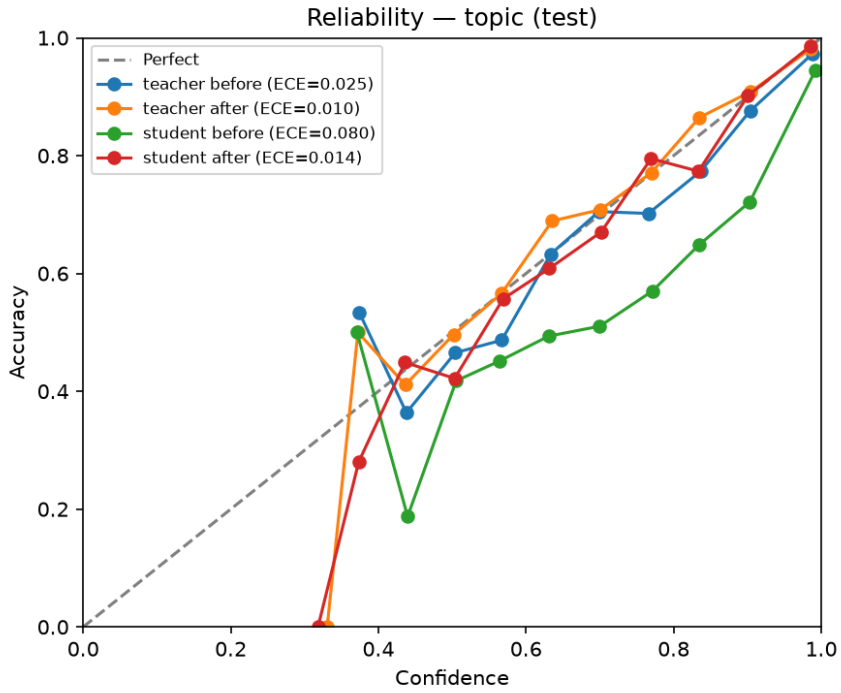
Distillation tăng đều cả ba metric so với TextCNN hard-label. Student gần như ngang teacher ở topic, thấp hơn ở sentiment/joint, nhưng nhỏ và nhanh hơn rất nhiều. Đây là trade-off phù hợp cho triển khai CPU.

4.8 Calibration

Bảng 4.9: ECE trước và sau temperature scaling trên test

Model	Task	T	ECE trước	ECE sau
Teacher	sentiment	1.366	0.0242	0.0215
Teacher	topic	1.230	0.0254	**0.0097**
Student	sentiment	1.930	0.0658	**0.0166**
Student	topic	1.823	0.0805	**0.0145**

Student overconfident hơn teacher trước calibration. Sau temperature scaling, ECE giảm mạnh, đặc biệt ở student. Accuracy không đổi vì temperature chỉ sửa confidence, không sửa argmax.

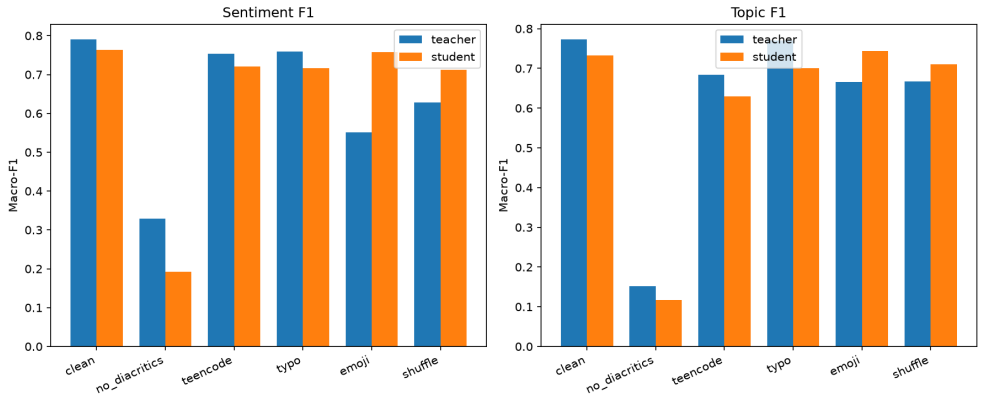


Hình 4.1: Reliability diagram cho topic sau calibration

4.9 Robustness

Bảng 4.10: Topic-F1 dưới các perturbation (800 câu test)

Variant	Teacher	Student
Clean	0.7727	0.7322
Không dấu	0.1517	0.1165
Teencode	0.6833	0.6303
Typo	0.7699	0.7005
Emoji	0.6661	**0.7440**
Đảo trật tự từ	0.6678	**0.7099**



Hình 4.2: So sánh robustness của teacher và student

Kết quả cho thấy mất dấu là điểm yếu nghiêm trọng nhất của cả hai mô hình. Teacher nhạy với emoji và đảo trật tự từ hơn student; student bền vững hơn ở hai perturbation này nhưng yếu hơn ở clean test.

Tóm tắt chương

Chương này trình bày kết quả một seed, kết quả 3 seed, kiểm định McNemar/bootstrap, ablation, per-class, distillation, calibration và robustness. Kết quả cho thấy keyword-aware PhoBERT cải thiện topic/joint, còn student distilled là trade-off hợp lý cho CPU. Chương tiếp theo mô tả demo và ý nghĩa thực tế.

4.10 Thảo luận

4.10.1 TextCNN và PhoBERT

Kết quả cho thấy PhoBERT frozen vượt TextCNN ở sentiment và joint, nhưng khoảng cách topic không lớn. Điều này hợp lý vì:

- PhoBERT đã học ngữ cảnh tiếng Việt từ corpus lớn, trong khi TextCNN chỉ học từ 11.426 câu train.
- Topic phụ thuộc mạnh vào keyword bề mặt; TextCNN với convolution 3/4/5 đã bắt được các cụm này khá tốt.
- Sentiment cần hiểu phủ định, mức độ và ngữ cảnh, nơi PhoBERT có lợi thế rõ hơn.

4.10.2 TextCNN multi-task có thực sự tốt hơn?

Không có bằng chứng nhất quán. Sentiment giảm nhẹ, topic tăng nhẹ, joint gần như không đổi. Có hai cách giải thích:

- Hai task có tương quan nhưng không hoàn toàn đồng nhất; hard sharing có thể gây negative transfer.
- TextCNN nhỏ, dung lượng hạn chế; chia sẻ hidden 256 cho hai head có thể tạo nút thắt.

Vì vậy báo cáo không tuyên bố multi-task luôn tốt hơn. Kết luận đúng là: với cấu hình này, multi-task không cải thiện rõ TextCNN, nhưng là nền tảng để thêm keyword head và distillation.

4.10.3 Keyword-aware: lợi ích và rủi ro

Keyword features giúp topic tăng 0.0205 so với PhoBERT frozen. Đây là mức cải thiện có ý nghĩa thống kê qua 3 seed. Tuy nhiên, cách làm này có rủi ro:

- Nếu keyword xuất hiện nhưng không phải chủ đề chính, model có thể bị kéo sai.
- Keyword list do con người thiết kế, có thể thiên lệch theo tập train.
- Câu không chứa keyword vẫn phụ thuộc hoàn toàn vào encoder.

Trong báo cáo, keyword được xem là *inductive bias* có kiểm soát, không phải rule cứng.

4.10.4 Teacher hay student?

Hai mô hình phục vụ hai mục đích khác nhau:

- **Teacher**: dùng khi cần chất lượng cao nhất, chấp nhận 63.68 ms/câu.
- **Student**: dùng khi cần throughput, chạy CPU, hoặc triển khai nội bộ với chi phí thấp.

Student nhỏ hơn 332 lần nhưng chỉ giảm khoảng 0.022 joint accuracy so với teacher. Đây là trade-off hợp lý cho nhiều kịch bản thực tế.

4.10.5 Câu nhiều chủ đề

Bài toán hiện là single-label. Với câu như "giảng viên tệ, cơ sở vật chất lỏ", model buộc phải chọn một chủ đề. Demo đã cảnh báo và hiển thị top-2, nhưng về bản chất đây là giới hạn của dữ liệu, không phải lỗi softmax. Muốn giải quyết đúng cần multi-label annotation.

4.10.6 Threats to validity

- **Internal validity**: cùng một pipeline, cùng split; đã kiểm tra trùng lặp. Tuy nhiên chưa chạy full grid hyperparameter.
- **External validity**: chỉ đánh giá trên UIT-VSFC, chưa cross-domain.
- **Construct validity**: topic là nhãn mức câu, không phải aspect; sentiment cũng mức câu.
- **Statistical validity**: 3 seed là nhỏ; McNemar/bootstrap giúp nhưng không thay thế nhiều seed hơn.

CHƯƠNG 5

DEMO VÀ Ý NGHĨA THỰC TẾ

5.1 Kiến trúc demo

Demo được xây dựng bằng Streamlit, cho phép chọn:

- **PhoBERT teacher**: chính xác hơn, chậm hơn.
- **TextCNN student**: nhỏ, nhanh, phù hợp CPU.

Mỗi dự đoán hiển thị:

- nhãn cảm xúc và chủ đề;
- confidence đã calibration;
- xác suất từng lớp;
- top-2 chủ đề;
- từ khóa chủ đề phát hiện;
- latency và số tham số;
- cảnh báo khi confidence thấp hoặc câu có nhiều chủ đề.

5.2 Quy trình sử dụng

1. Nhập một câu phản hồi.
2. Chọn teacher hoặc student.
3. Xem nhãn, confidence, top-2 và keyword.

4. Nếu có cảnh báo multi-topic, người dùng biết rằng model chỉ chọn chủ đề trội.
5. Chuyển kết quả cho người phụ trách để xem lại.

5.3 Ý nghĩa thực tế

Giá trị của hệ thống không nằm ở việc thay thế con người mà ở khả năng **triage** phản hồi:

- Lọc nhanh các phản hồi tiêu cực.
- Nhóm phản hồi theo chủ đề để chuyển đúng đơn vị.
- Ưu tiên các vấn đề nghiêm trọng.
- Theo dõi xu hướng giữa các học kỳ.
- Hỗ trợ kiểm định và cải tiến chất lượng.

Ví dụ, cặp *negative* + *lecturer* gợi ý cần xem lại phản hồi về giảng dạy; *negative* + *facility* gợi ý cần kiểm tra phòng học/thiết bị. Hệ thống chạy trên CPU, chi phí thấp, có thể triển khai nội bộ để tránh gửi dữ liệu sinh viên lên cloud.

5.4 Hạn chế của demo

- Chỉ là single-label topic, không phải multi-label.
- Chưa xử lý tốt mất dấu và teencode.
- Confidence đã calibration nhưng không đảm bảo đúng trong mọi miền.
- Không có đánh giá cross-domain.

Tóm tắt chương

Chương này mô tả demo Streamlit, quy trình sử dụng và ý nghĩa thực tế của hệ thống. Điểm chính là hệ thống đóng vai trò hỗ trợ triage phản hồi, không thay thế con người, và đã có cảnh báo multi-topic cùng confidence đã calibration. Chương tiếp theo trình bày các quyết định kỹ nghệ phần mềm và khả năng tái lập.

CHƯƠNG 6

KỸ NGHỆ PHẦN MỀM VÀ TÁI LẬP

Một điểm quan trọng của môn Lập trình Python nâng cao là sản phẩm không chỉ chạy được mà còn phải dễ đọc, dễ kiểm thử và tái lập. Chương này mô tả các quyết định kỹ nghệ phần mềm của nhóm.

6.1 Cấu trúc repository

```
configs/        # hyperparameters YAML
data/raw/       # dữ liệu gốc, bất biến
data/processed/ # dữ liệu đã xử lý, không commit
src/data/       # load, preprocess, dataset, EDA
src/models/     # TextCNN, PhoBERT heads, baseline
src/            # train, predict, calibration, robustness
app/            # Streamlit demo
reports/        # báo cáo, metric, hình
tests/          # unit tests
scripts/        # tiện ích môi trường
```

Các nguyên tắc:

- Không sửa tay dữ liệu trong `data/processed/`; mọi biến đổi nằm trong script.
- Không commit dữ liệu, model, cache hoặc file checkpoint.
- Mỗi model có thư mục báo cáo riêng trong `reports/`.
- `results.csv` ở root là nguồn tổng hợp duy nhất cho các model.

6.2 Pipeline dữ liệu

Pipeline gồm các bước:

1. `src.data.load`: đọc file gốc, kiểm tra số dòng và label mapping.
2. `src.data.preprocess`: chuẩn hóa Unicode, tách từ, cache tokenized split.
3. `src.data.dataset`: tạo vocabulary, encode, collate cho từng loại model.
4. Trainer: load config, set seed, train, evaluate dev, chọn checkpoint.
5. Evaluator: ghi metric, per-class, confusion matrix và prediction.

Việc cache tokenized split giúp các lần chạy sau nhanh hơn và giảm sai lệch do tiền xử lý khác nhau.

6.3 Quản lý cấu hình

Mỗi thí nghiệm dùng một file YAML trong `configs/`. Config ghi:

- seed, λ_t, các tham số model;
- batch size, learning rate, số epoch, patience;
- đường dẫn dữ liệu và report.

CLI chỉ override các giá trị cần thiết như `--seed`, `--lambda-topic`, `--smoke-test`. Config thực tế được lưu lại trong checkpoint và metric JSON để truy vết.

6.4 Kiểm thử

Bộ test hiện có 33 test, bao phủ:

- môi trường và import;
- load dữ liệu, label mapping, EDA;
- metric, dataset, model shape;
- keyword features, distillation dataset;
- calibration ECE và report paths.

Ngoài unit test, nhóm chạy smoke test cho tất cả trainer:

```
python -m src.train_textcnn --task both --smoke-test ...
python -m src.train_textcnn_multitask --smoke-test ...
python -m src.train_phobert_multitask --smoke-test ...
python -m src.train_phobert_keyword_multitask --smoke-test ...
python -m src.train_textcnn_distill --smoke-test ...
```

Smoke test kiểm tra load dữ liệu, forward/backward, lưu checkpoint, load lại và predict một câu.

6.5 Tái lập

Các lệnh chính:

```
.\scripts\activate.ps1
python -m src.data.load
python -m src.data.eda
python -m src.models.baseline
python -m src.train_textcnn --task both
python -m src.train_textcnn_multitask
python -m src.train_phobert_multitask
python -m src.train_phobert_keyword_multitask
python -m src.data.teacher_logits
python -m src.train_textcnn_distill
python -m src.calibration
python -m src.evaluate_robustness
python -m src.statistical_tests
.\scripts\run_demo.ps1
```

Để tái lập kết quả 3 seed:

```
python -m src.train_textcnn_multitask --seed 42
python -m src.train_textcnn_multitask --seed 123
python -m src.train_textcnn_multitask --seed 2024
```

6.6 Git và báo cáo

Nhóm dùng Conventional Commits:

```
feat(phobert): add keyword-aware multi-task model
feat(distill): add TextCNN student distillation
chore(results): add three-seed evaluation
docs(report): add LaTeX midterm report
```

Mỗi thay đổi lớn có commit riêng, kèm mô tả và kết quả. Báo cáo được tổ chức theo model/stage trong `reports/`, có index tại `reports/README.md`.

6.7 Hạn chế kỹ nghệ

- Chưa có CI tự động; test được chạy thủ công trước commit.
- Chưa có Docker/API; demo hiện là Streamlit chạy local.
- Chưa có logging tập trung; trainer in ra stdout và lưu metric JSON.
- Chưa có benchmark đa nền tảng; latency đo trên một CPU cụ thể.

Tóm tắt chương

Chương này trình bày cấu trúc repository, pipeline dữ liệu, quản lý config, kiểm thử, tái lập và quy trình Git. Các quyết định này giúp kết quả có thể kiểm tra lại, đồng thời chỉ ra các hạn chế kỹ nghệ còn lại như thiếu CI và Docker. Chương cuối tổng kết toàn bộ đề tài.

CHƯƠNG 7

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 Kết luận

Đề tài đã xây dựng một pipeline multi-task hoàn chỉnh cho UIT-VSFC, so sánh TextCNN và PhoBERT, bổ sung keyword-aware topic head, đánh giá 3 seed và kiểm định thống kê. Kết quả chính:

- PhoBERT keyword-aware đạt mean test sentiment-F1 0.7760, topic-F1 0.7597, joint 0.7989.
- Cải thiện topic và joint so với PhoBERT frozen là nhất quán qua 3 seed.
- TextCNN student distilled nhỏ hơn 332 lần, nhanh hơn 27.6 lần, vẫn giữ topic-F1 0.7607 và joint 0.7766.
- Calibration giảm ECE mạnh cho student; robustness chỉ ra mất dấu là điểm yếu lớn nhất.
- Demo Streamlit hỗ trợ chọn model, confidence đã calibration, top-2 và cảnh báo multi-topic.

7.2 Hạn chế

- PhoBERT chưa được fine-tune; chỉ train head.
- Dataset nhỏ, một miền, chưa kiểm chứng cross-domain.
- Bài toán topic là single-label; câu nhiều chủ đề chưa được xử lý đúng bản chất.
- Chưa có multi-label annotation.
- Robustness với mất dấu và teencode còn yếu.

7.3 Bài học kinh nghiệm

1. **Dữ liệu quan trọng hơn model.** Kiểm tra label mapping và phân bố lớp giúp tránh nhiều lỗi khó hiểu về sau.
2. **Baseline phải chạy trước.** TF-IDF đơn giản nhưng cho thấy mức độ khó thật sự của bài toán và là mốc so sánh đáng tin.
3. **Một seed là chưa đủ.** Phương sai giữa các seed của PhoBERT frozen khá lớn; báo cáo mean $\pm$ std và kiểm định thống kê cần thiết hơn một con số đẹp.
4. **Chọn model bằng dev.** Test chỉ nên được đánh giá một lần cho cấu hình cuối; nếu không, kết quả sẽ bị lạc quan.
5. **Đánh giá phải đi kèm giới hạn.** Calibration và robustness cho thấy model yếu ở đâu; multi-topic warning cho thấy bài toán chưa được giải quyết trọn vẹn.
6. **Đơn giản có giá trị.** Distillation cho thấy một student nhỏ có thể giữ phần lớn chất lượng với chi phí thấp hơn nhiều.

7.4 Checklist tái lập

- Cài đúng Python 3.12 và dependencies.
- Tải đúng UIT-VSFC, kiểm tra số dòng và label mapping.
- Chạy EDA và lưu hình/bảng.
- Chạy baseline trước khi train model học sâu.
- Chạy 3 seed cho model chính.
- Chạy calibration, robustness và statistical tests.
- Chạy ‘pytest‘ và smoke test.
- Compile lại báo cáo LaTeX.

7.5 Hướng phát triển

1. Fine-tune 1–2 layer cuối PhoBERT hoặc dùng LoRA nếu có GPU.
2. Gán nhãn multi-label cho một tập con và xây dựng multi-label topic head.
3. Bổ sung cross-domain test trên dữ liệu review ngoài UIT-VSFC.

4. Data augmentation cho teencode/không dấu.
5. Calibration nâng cao (temperature theo lớp, label smoothing).
6. Đóng gói API/Docker và dashboard cho đơn vị đảm bảo chất lượng.

7.6 Tổng kết

Đề tài đã trả lời được bốn câu hỏi thực nghiệm: TextCNN và PhoBERT khác nhau thế nào trên UIT-VSFC; multi-task có giúp ích không; keyword-aware có cải thiện topic không; và có thể nén mô hình xuống CPU mà vẫn giữ chất lượng hay không. Kết quả cho thấy lợi ích rõ nhất đến từ PhoBERT và keyword-aware head, trong khi multi-task TextCNN chưa đủ bằng chứng để vượt single-task.

Về mặt ứng dụng, hệ thống phù hợp nhất với vai trò *triage*: lọc phản hồi tiêu cực, gợi ý chủ đề và ưu tiên xem xét. Hệ thống không thay thế con người, không đưa ra kết luận về cá nhân giảng viên và cần được kiểm tra lại trước khi dùng cho quyết định hành chính. Các hạn chế về multi-topic, mất dấu và cross-domain là hướng mở rộng tự nhiên của đề tài.

TÀI LIỆU THAM KHẢO

[1] Nguyen, V. D., Nguyen, D. Q., Nguyen, T. T., and Pham, T. H. (2018). *UIT-VSFC: Vietnamese Students' Feedback Corpus for Sentiment Analysis*. In Proceedings of the 10th International Conference on Knowledge and Systems Engineering (KSE).

[2] Nguyen, D. Q. and Nguyen, A. T. (2020). *PhoBERT: Pre-trained Language Models for Vietnamese*. In Findings of the Association for Computational Linguistics: EMNLP 2020.

[3] Kim, Y. (2014). *Convolutional Neural Networks for Sentence Classification*. In Proceedings of EMNLP 2014.

[4] Caruana, R. (1997). *Multitask Learning*. Machine Learning, 28(1), 41–75.

[5] Hinton, G., Vinyals, O., and Dean, J. (2015). *Distilling the Knowledge in a Neural Network*. NIPS Deep Learning and Representation Learning Workshop.

[6] Guo, C., Pleiss, G., Sun, Y., and Weinberger, K. Q. (2017). *On Calibration of Modern Neural Networks*. In Proceedings of ICML 2017.

[7] McNemar, Q. (1947). *Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages*. Psychometrika, 12(2), 153–157.